

MindTrack

Sistema de apoyo para la identificación temprana del riesgo de depresión en estudiantes universitarios mediante Ciencia de Datos

Documento de Formulación y Plan de Trabajo — Entregable 1

Unidad 1: Formulación del problema y diseño del proyecto

Integrantes: Nicoll y Valentina

Reto: Salud pública — riesgo de depresión en estudiantes universitarios

Fecha: 3 de agosto de 2026

Universidad de La Sabana — Ciencia de Datos

1. Descripción del problema y contexto

La salud mental se ha convertido en uno de los principales desafíos para las instituciones de educación superior debido al incremento de casos de depresión entre estudiantes universitarios. Factores como la presión académica, el estrés financiero, los hábitos de sueño, la satisfacción con los estudios y los antecedentes familiares pueden influir significativamente en el bienestar emocional de los estudiantes.

Actualmente, la detección de estudiantes en riesgo depende en gran medida de que ellos mismos soliciten ayuda o de la observación directa por parte de profesionales, lo que deja por fuera casos que podrían identificarse de forma más temprana. La Ciencia de Datos ofrece la posibilidad de analizar grandes volúmenes de información institucional para identificar patrones asociados con el riesgo de depresión y generar herramientas de apoyo a la toma de decisiones, sin sustituir el criterio profesional de psicólogos y equipos de bienestar universitario.

Es importante precisar el alcance: el modelo no diagnostica depresión. Su función es identificar estudiantes con mayor probabilidad de riesgo, como insumo para que las Oficinas de Bienestar Universitario prioricen intervenciones tempranas.

2. Pregunta analítica central y preguntas secundarias

Pregunta central

¿Qué tan bien puede un modelo de clasificación estimar el riesgo de depresión de un estudiante universitario a partir de variables académicas, personales y socioeconómicas?

Preguntas secundarias

- ¿Qué variables presentan mayor influencia en el riesgo de depresión?
- ¿Cuál es el desempeño de un modelo de clasificación para identificar estudiantes con riesgo de depresión?
- ¿Qué factores académicos, personales y socioeconómicos muestran mayor relación con la variable objetivo?
- ¿Cómo podrían utilizarse los resultados del modelo como apoyo para la toma de decisiones en programas de bienestar universitario?

3. Objetivos analíticos y de negocio (SMART)

Objetivo de negocio

Apoyar a las Oficinas de Bienestar Universitario en la identificación temprana de estudiantes con riesgo de depresión mediante un sistema basado en datos, desarrollado en un plazo de 14 semanas, que sirva como insumo adicional a los mecanismos actuales de detección basados en autoreporte.

Objetivo analítico

Desarrollar y evaluar, en un plazo de 10 semanas, un modelo de clasificación supervisada que estime la probabilidad de riesgo de depresión en estudiantes universitarios a partir de variables académicas, personales y socioeconómicas, alcanzando un desempeño igual o superior a 0.75 en F1-score sobre el conjunto de prueba.

Objetivos específicos

- Analizar y comprender las características del conjunto de datos seleccionado (estructura, calidad, distribución de variables).
- Identificar las variables con mayor relación respecto al riesgo de depresión mediante análisis exploratorio y de correlación.
- Construir y evaluar un modelo de clasificación supervisada para estimar el riesgo de depresión, comparando al menos dos algoritmos.
- Interpretar los resultados obtenidos y analizar su utilidad como herramienta de apoyo para instituciones educativas.

4. Identificación y justificación de las fuentes de datos

Fuente principal: Student Depression Dataset (Kaggle)

Conjunto de datos con 27.901 registros de estudiantes universitarios en India, con 18 variables que incluyen presión académica, presión laboral, CGPA, satisfacción con los estudios, horas de sueño, hábitos alimenticios, estrés financiero, antecedentes familiares de enfermedad mental, pensamientos suicidas y la variable objetivo Depression (binaria). Calidad: prácticamente sin datos faltantes (solo 3 valores nulos en Financial Stress). Completitud: alta. Trazabilidad: fuente pública en Kaggle, con diccionario de variables documentado. La variable objetivo está razonablemente balanceada (58.5% con depresión, 41.5% sin ella), lo cual favorece el entrenamiento de un modelo de clasificación.

Limitación identificada: los datos corresponden a estudiantes de India, por lo que los patrones encontrados no son directamente extrapolables al contexto colombiano sin un ejercicio de contextualización.

Fuente complementaria: Encuesta Nacional de Salud Mental (ENSM)


Encuesta del Ministerio de Salud y Protección Social de Colombia, utilizada no como insumo de entrenamiento del modelo sino como referencia para contextualizar e interpretar los resultados desde la realidad colombiana, contrastando prevalencias y factores de riesgo reportados a nivel nacional con los patrones encontrados en el dataset principal.

Diccionario de datos preliminar (fuente principal)

Variable	Tipo	Descripción / observación
Depression	Binaria (target)	1 = presenta riesgo/depresión, 0 = no. Variable objetivo del modelo.
Age	Numérica	Edad del estudiante.
Gender	Categórica	Género reportado.
Academic Pressure	Ordinal (0-5)	Nivel de presión académica autoreportado.
Study Satisfaction	Ordinal (0-5)	Satisfacción con los estudios.
CGPA	Numérica	Promedio académico acumulado.
Sleep Duration	Categórica ordinal	Rango de horas de sueño.
Dietary Habits	Categórica	Calidad de hábitos alimenticios.
Financial Stress	Ordinal (1-5)	Nivel de estrés financiero. Contiene 3 valores nulos.
Have you ever had suicidal thoughts?	Binaria	Variable sensible — requiere tratamiento ético especial (ver sección 8).
Family History of Mental Illness	Binaria	Antecedentes familiares de enfermedad mental.
Profession	Categórica	99.9% de los registros = 'Student'. Variable con varianza casi nula; candidata a exclusión.
City / Degree	Categórica	52 ciudades y 28 programas académicos distintos; alta cardinalidad, requiere agrupación.

5. Arquitectura preliminar de datos: pipeline propuesto

El siguiente diagrama resume el flujo de trabajo propuesto, desde la ingesta de los datos hasta la generación del reporte de apoyo para Bienestar Universitario:



6. Justificación del enfoque de modelado

Se propone un enfoque de aprendizaje supervisado, específicamente clasificación binaria, para estimar el riesgo de depresión. La justificación epistemológica es la siguiente:

- La variable objetivo (Depression) está etiquetada de forma explícita en los datos disponibles, lo que hace innecesario —y menos eficiente— recurrir a técnicas no supervisadas como clustering, cuyo propósito es descubrir estructuras desconocidas en ausencia de etiquetas.
- El objetivo del proyecto es predictivo (estimar la probabilidad de un resultado conocido para casos nuevos), no exploratorio ni de segmentación, lo que se alinea directamente con el paradigma de clasificación supervisada.
- El balance razonable de clases (58.5% / 41.5%) permite entrenar modelos de clasificación estándar sin necesidad de técnicas complejas de balanceo desde el inicio.

Se evaluarán al menos dos algoritmos de clasificación (por ejemplo, regresión logística como modelo base interpretable, y un modelo de ensamble como Random Forest o Gradient Boosting) para contrastar desempeño frente a interpretabilidad,

un criterio central dado que el resultado debe ser explicable a un equipo de Bienestar Universitario y no solo preciso estadísticamente.

7. Plan de trabajo: cronograma (semanas 3–14)

Semana	Actividad	Entregable / hito	Responsable
3–5	Análisis exploratorio de datos (EDA) y limpieza inicial	Notebook EDA	Nicoll / Valentina
5–6	Tratamiento de nulos, codificación de categóricas, eliminación de variables sin varianza	Dataset procesado	Nicoll / Valentina
6–7	Feature engineering y análisis de correlaciones	Diccionario de datos final	Nicoll / Valentina
7–8	Entrenamiento de modelo base (regresión logística)	Modelo baseline	Nicoll / Valentina
8–9	Entrenamiento de modelo de ensamble y comparación	Modelo candidato	Nicoll / Valentina
9–10	Validación cruzada, métricas (F1, AUC, matriz de confusión)	Reporte de validación	Nicoll / Valentina
10–11	Interpretación de resultados (importancia de variables) y reflexión ética	Sección de interpretación	Nicoll / Valentina
11–12	Redacción y consolidación del documento final	Borrador completo	Nicoll / Valentina
13	Revisión de pares (peer review) interna	Documento revisado	Nicoll / Valentina
14	Ajustes finales, subida a repositorio y sistema de gestión académica	Entregable final	Nicoll / Valentina

8. Matriz de roles y responsabilidades

Integrante	Rol	Responsabilidades principales
Nicoll	Liderazgo técnico	Liderazgo del análisis y desarrollo técnico del proyecto, participando también en la documentación, gestión, revisión de entregables y toma de decisiones del equipo.
Valentina	Liderazgo de gestión	Liderazgo de la gestión y documentación del proyecto, participando también en el análisis de datos, desarrollo y validación de modelos, revisión técnica y toma de decisiones del equipo.

Ambas integrantes participan conjuntamente en las decisiones de alcance, la revisión de pares y la entrega final, garantizando comunicación efectiva y trazabilidad de las decisiones del equipo.

9. Reflexión ética e implicaciones con el ODS 9 (Meta 9.b)

Datos sensibles

El conjunto de datos incluye variables altamente sensibles, en particular pensamientos suicidas y antecedentes familiares de enfermedad mental. Estas variables requieren tratamiento especial: no se usarán para etiquetar o exponer individuos, se trabajará siempre de forma agregada y anonimizada, y los resultados del modelo se comunicarán exclusivamente a profesionales autorizados de Bienestar Universitario, nunca de forma individualizada a terceros.

Riesgo de sesgo

La fuente principal proviene de estudiantes en India, lo que introduce un riesgo de sesgo cultural y contextual al aplicar los hallazgos en un entorno colombiano. Adicionalmente, la variable Profession presenta varianza casi nula y algunas ciudades y programas académicos están sobrerrepresentados, lo que puede sesgar el modelo hacia patrones no generalizables.

Medidas de mitigación

- Uso de la ENSM como referencia de contraste para evaluar si los patrones encontrados son consistentes con el contexto colombiano antes de cualquier recomendación operativa.
- Evaluación del desempeño del modelo por subgrupos (género, rango de edad) para detectar posibles inequidades antes de su uso.
- El modelo se plantea explícitamente como herramienta de apoyo a la decisión humana, nunca como mecanismo de diagnóstico automático ni de decisión autónoma.

Vínculo con el ODS 9 (Meta 9.b)

El proyecto aporta innovación tecnológica aplicada —analítica predictiva basada en datos— para fortalecer la capacidad de las instituciones educativas, particularmente en contextos en desarrollo como el colombiano, de identificar y atender tempranamente riesgos de salud mental. Esto se alinea directamente con la Meta 9.b de fomentar el desarrollo tecnológico endógeno y la innovación con impacto sectorial en países en desarrollo.

10. Referencias (APA 7.^a edición)

Kaggle. (s.f.). Student Depression Dataset. Kaggle.

Kelleher, J., & Tierney, B. (2018). Data science: A practical introduction. CRC Press.

Ministerio de Salud y Protección Social de Colombia. (s.f.). Encuesta Nacional de Salud Mental (ENSM).

Naciones Unidas. (s.f.). Objetivo 9: Industria, innovación e infraestructura. Objetivos de Desarrollo Sostenible.

O'Neil, C. (2016). Weapons of math destruction. Crown Publishing.

Patil, D. J., & Davenport, T. H. (2012). Data scientist: The sexiest job of the 21st century. Harvard Business Review.

Provost, F., & Fawcett, T. (2013). Data science for business. O'Reilly Media.